
CENTRO UNIVERSITÁRIO DE BALSAS

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

André Rocha Figueredo

Michel Guido Teixeira

Mickael Sousa Miranda

Pedro Igor Ferreira De Carvalho

Dhonantan dos Santos Anchieta Junior

DOCUMENTO TÉCNICO DO PROJETO - VERSÃO 2.0

Da Roça Inteligente: Limpeza, Saneamento e Análise Exploratória de Dados

BALSAS

2026

1. INTRODUÇÃO

O projeto Sistema Inteligente de Gestão para a Da Roça foi desenvolvido a partir da necessidade de melhorar o acompanhamento do estoque da empresa Da Roça - Agropecuária & Pet. Na TED 01, o problema de dados foi definido como a análise de informações de vendas e estoque para identificar padrões de consumo e apoiar a identificação antecipada de produtos que podem necessitar de reposição.

A TED 02 dá continuidade ao projeto por meio da preparação, limpeza, saneamento e análise exploratória do conjunto de dados selecionado. O objetivo desta etapa é verificar a qualidade da base, realizar tratamentos justificados e compreender os padrões presentes nos dados, relacionando os resultados às funcionalidades previstas no MVP.

2. CONTINUIDADE DA TED 01: PROBLEMA, SOLUÇÃO E BASE SELECIONADA

A solução proposta é um sistema web apoiado por Inteligência Artificial, com funcionalidades de cadastro de produtos, registro de vendas, dashboard, identificação de estoque baixo, alertas, análise histórica e apoio às necessidades de reposição. A IA tem função de apoio à decisão e não substitui a avaliação do gestor.

Na TED 01 foi selecionado o Retail Store Inventory Forecasting Dataset, disponibilizado no Kaggle por Anirudh Singh Chauhan. Trata-se de uma base sintética voltada ao gerenciamento de estoque e à previsão de demanda. A escolha ocorreu porque a base reúne informações de vendas, estoque, pedidos e previsão de demanda, além de variáveis temporais e contextuais.

As variáveis consideradas mais diretamente relacionadas ao problema são Inventory Level, Units Sold, Units Ordered e Demand Forecast. Elas permitem observar disponibilidade, consumo, reposição e demanda esperada.

3. CARREGAMENTO E INSPEÇÃO DA BASE

O arquivo retail_store_inventory.csv foi carregado em Python com a biblioteca pandas. A inspeção confirmou 73.100 registros e 15 colunas. Os dados abrangem 731 datas, de 01/01/2022 a 01/01/2024, cinco lojas e vinte produtos. Cada combinação diária fornece informações de estoque, vendas, pedidos, previsão de demanda, preço e fatores contextuais.

Variável	Descrição
Date	Data do registro
Store ID	Identificação da loja

Product ID	Identificação do produto
Category	Categoria
Region	Região
Inventory Level	Nível de estoque
Units Sold	Unidades vendidas
Units Ordered	Unidades solicitadas
Demand Forecast	Previsão de demanda
Price	Preço
Discount	Desconto
Weather Condition	Condição climática
Holiday/Promotion	Indicador de feriado/promoção
Competitor Pricing	Preço do concorrente
Seasonality	Sazonalidade

Tabela 1 - Estrutura do conjunto de dados analisado.

4. QUALIDADE DOS DADOS E TRATAMENTOS REALIZADOS

4.1 Valores ausentes e duplicados

A verificação não identificou valores ausentes em nenhuma das 15 colunas. Também não foram encontrados registros totalmente duplicados. Portanto, não foi necessário excluir linhas nem realizar imputação de valores.

4.2 Tipos de dados

A coluna Date estava originalmente armazenada como texto e foi convertida para o tipo de data. As variáveis quantitativas já estavam em formatos numéricos adequados, e as variáveis de identificação e categorização foram mantidas como texto/categorias. A conversão da data é necessária para permitir análises temporais consistentes.

4.3 Valores inválidos ou inconsistentes

Foram verificadas ocorrências negativas nas variáveis quantitativas. Inventory Level, Units Sold, Units Ordered, Price, Discount e Competitor Pricing não apresentaram valores negativos. Entretanto, Demand Forecast apresentou 673 registros negativos, com mínimo de -9,99.

Como Demand Forecast representa uma quantidade esperada de demanda e, no contexto operacional do projeto, não existe demanda negativa, os 673 valores negativos foram ajustados para zero. A decisão preserva os registros e evita atribuir significado operacional a quantidades impossíveis. Essa intervenção deve ser considerada nas etapas posteriores de modelagem, pois a base é sintética e o valor negativo pode resultar do processo utilizado para gerá-la.

4.4 Outliers

Foi aplicado o critério do intervalo interquartil (IQR) como mecanismo de identificação, e não como regra automática de exclusão. Foram sinalizados 715 valores em Units Sold acima do limite superior de 434 e 732 valores em Demand Forecast acima de aproximadamente 439,63. Esses valores foram mantidos, pois permanecem dentro dos limites observados da base (até 499 unidades vendidas e 518,55 de demanda prevista) e podem representar períodos de demanda elevada. A remoção automática poderia eliminar justamente comportamentos relevantes para o problema de reposição.




Figura 1 - Boxplot de unidades vendidas. Os pontos extremos foram mantidos para preservar possíveis períodos de alta demanda.

4.5 Atributos irrelevantes ou redundantes

Nenhuma coluna foi removida nesta etapa. As variáveis Inventory Level, Units Sold, Units Ordered e Demand Forecast são centrais ao problema. As demais podem ser úteis para investigar fatores associados à demanda. Entretanto, a análise de correlação revelou relação muito alta entre Price e Competitor Pricing, aspecto que deverá ser observado em uma futura etapa de modelagem para evitar redundância desnecessária.

5. DESCRIÇÃO DA BASE APÓS O TRATAMENTO

Após a preparação, a base permaneceu com 73.100 registros e 15 colunas. Não houve remoção de linhas. A principal transformação foi a conversão de Date para data e o ajuste para zero dos 673 valores negativos de Demand Forecast. A versão tratada foi exportada como retail_store_inventory_processed.csv.

6. ESTATÍSTICAS DESCRITIVAS

Variável	Média	Desvio-padrão	Mínimo	Mediana	Máximo
Inventory Level	274,47	129,95	50	273	500
Units Sold	136,46	108,92	0	107	499
Units Ordered	110,0	52,28	20	110	200
Demand Forecast	141,53	109,21	0	113,02	518,55
Price	55,14	26,02	10	55,05	100
Discount	10,01	7,08	0	10	20
Competitor Pricing	55,15	26,19	5,03	55,01	104,94

Tabela 2 - Estatísticas descritivas após o tratamento.

As unidades vendidas apresentam média de 136,46 e mediana de 107, indicando uma distribuição com presença de valores altos que elevam a média. O nível de estoque apresenta média de 274,47 unidades. A previsão de demanda possui média de 141,53 após o tratamento dos valores negativos. Essas medidas fornecem uma visão inicial do comportamento geral da base, mas devem ser interpretadas em conjunto com as distribuições e relações entre variáveis.

7. ANÁLISE EXPLORATÓRIA DOS DADOS

7.1 Distribuição das unidades vendidas




Figura 2 - Distribuição das unidades vendidas.

A distribuição mostra maior concentração de registros em volumes menores e intermediários de venda, com uma cauda que alcança valores próximos de 500 unidades. Esse comportamento explica a diferença entre média e mediana e reforça a decisão de não remover automaticamente os valores altos: eles podem representar situações importantes de maior consumo.

7.2 Relação entre vendas e previsão de demanda




Figura 3 - Relação entre unidades vendidas e previsão de demanda.

Foi encontrada correlação de aproximadamente 0,997 entre Units Sold e Demand Forecast. O gráfico confirma uma relação linear extremamente forte: à medida que as unidades vendidas aumentam, a previsão de demanda também aumenta. Para o projeto, isso demonstra que a previsão de demanda está fortemente associada ao histórico de vendas. Ao mesmo tempo, essa proximidade exige atenção em futuras modelagens, pois a variável de previsão pode conter informação muito próxima da variável de vendas.

7.3 Vendas por categoria




Figura 4 - Média de unidades vendidas por categoria.

As médias entre as cinco categorias são próximas. Furniture apresentou a maior média, cerca de 137,77 unidades por registro, enquanto Electronics apresentou aproximadamente 135,01. A pequena diferença sugere que, nesta base sintética, a categoria isoladamente não produz grandes contrastes no volume médio vendido. Portanto, decisões de reposição não deveriam depender apenas da categoria.

7.4 Comportamento temporal




Figura 5 - Média mensal de unidades vendidas entre janeiro de 2022 e dezembro de 2023.

A série mensal apresenta oscilações ao longo do período, sem crescimento ou queda contínua evidente. Julho de 2023 se destaca entre os meses com maior volume médio, enquanto fevereiro tende a apresentar totais menores, também influenciados pela menor quantidade de dias. Para uso no MVP, o acompanhamento temporal deve considerar médias e padrões por produto, e não apenas totais mensais agregados.

7.5 Relações entre variáveis




Figura 6 - Matriz de correlação das principais variáveis numéricas.

Além da correlação de aproximadamente 0,997 entre Units Sold e Demand Forecast, foi observada correlação moderada de aproximadamente 0,590 entre Inventory Level e Units Sold. Price e Competitor Pricing apresentam correlação de aproximadamente 0,994. Units Ordered apresentou correlação praticamente nula com Units Sold e Demand Forecast na análise agregada. Isso sugere que, nesta base, os pedidos não acompanham diretamente as vendas quando observados de forma global, o que torna relevante investigar defasagens temporais e análises por produto/loja nas próximas etapas.

8. PADRÕES, TENDÊNCIAS E INTERPRETAÇÃO

Os resultados revelam quatro pontos principais. Primeiro, vendas e previsão de demanda apresentam associação extremamente forte. Segundo, o nível de estoque possui relação moderada com as vendas, indicando que os registros de maior venda tendem a aparecer associados a níveis de estoque maiores, característica que deve ser compreendida antes de

transformar a relação em regra de reposição. Terceiro, as categorias possuem médias de vendas semelhantes. Quarto, a quantidade solicitada não apresentou relação linear relevante com as vendas na análise agregada.

A análise também mostrou que a base possui boa completude estrutural, sem valores ausentes e sem duplicatas, mas contém uma inconsistência conceitual importante: previsões de demanda negativas. O tratamento desse problema evidencia por que a etapa de saneamento deve preceder qualquer modelagem.

9. RELAÇÃO DOS RESULTADOS COM O PROBLEMA E O MVP

O problema do projeto é acompanhar o estoque e identificar antecipadamente produtos que possam precisar de reposição. A análise exploratória confirma que as variáveis escolhidas na TED 01 permitem investigar esse problema. Units Sold fornece o histórico de consumo; Inventory Level informa a disponibilidade; Demand Forecast representa a demanda esperada; e Units Ordered registra a quantidade solicitada.

Para o MVP, esses dados podem alimentar o dashboard, destacar produtos com estoque reduzido, apresentar histórico de vendas e apoiar alertas de reposição. Entretanto, os resultados também indicam que uma regra simples baseada apenas em uma variável seria insuficiente. A recomendação de reposição deve combinar estoque atual, comportamento recente das vendas, previsão de demanda e, quando pertinente, pedidos já realizados.

Não foi necessário alterar o problema central ou o escopo geral do MVP nesta etapa. A principal revisão é metodológica: futuras análises devem considerar relações temporais por produto e loja, e a variável Demand Forecast deve ser usada com cautela devido à sua correlação quase perfeita com Units Sold.

10. LIMITAÇÕES

A principal limitação permanece a natureza sintética do conjunto de dados. Os resultados não representam diretamente a operação real da Da Roça. A base também não contém informações específicas importantes para uma implantação real, como fornecedores, prazo de entrega, estoque mínimo definido pela empresa e particularidades dos produtos agropecuários. Assim, os resultados servem para desenvolver e validar a abordagem analítica, mas uma implantação futura deverá utilizar dados reais da empresa.

11. CONCLUSÃO

A TED 02 permitiu transformar a base selecionada em uma versão mais adequada para análise. A inspeção confirmou 73.100 registros, ausência de dados faltantes e ausência de duplicatas. A coluna de data foi ajustada para o tipo adequado e 673 previsões negativas de demanda foram tratadas. Possíveis outliers foram identificados, avaliados e mantidos quando apresentavam interpretação plausível.

A análise exploratória identificou forte relação entre vendas e previsão de demanda, relação moderada entre vendas e nível de estoque e elevada associação entre preço do produto e preço do concorrente. Esses achados ajudam a compreender a estrutura da base e orientam as próximas etapas de modelagem. Para o Da Roça Inteligente, a principal contribuição é demonstrar como dados de estoque, vendas e demanda podem ser organizados para apoiar dashboards, alertas e futuras recomendações de reposição.

12. ORGANIZAÇÃO DOS ARQUIVOS DA TED 02

A entrega inclui a base tratada `retail_store_inventory_processed.csv`, o notebook `TED02_limpeza_eda.ipynb`, os gráficos utilizados na análise e este Documento Técnico v2.0. O notebook registra as etapas de carregamento, inspeção, tratamento, estatísticas e análise exploratória, permitindo reproduzir os principais resultados.

13. REFERÊNCIAS

CHAUHAN, Anirudh Singh. Retail Store Inventory Forecasting Dataset. Kaggle, 2025. Base sintética para gerenciamento de estoque e previsão de demanda. Acesso em 2026.

KAGGLE. Retail Store Inventory Forecasting Dataset. Conjunto de dados disponibilizado por Anirudh Singh Chauhan. Acesso em 2026.